Comparación de modelos y selección de variables

Contents

T	Introduction	T
2	Comparación de modelos	2
3	Métodos de construcción de modelos a partir de un conjunto de variables 3.1 Selección de variables significativas 3.2 Best subset selection 3.3 Método Forward-Stepwise 3.4 Método Backward-Stepwise 3.5 Eligiendo el mejor modelo utilizando subconjuntos de validación 3.6 Eligiendo el mejor modelo utilizando Cross-Validation	3 5 8 9 11 12
1	Introducción	
d :	<pre>= read.csv("datos/Hitters.csv") = d[,-1] r(d)</pre>	
	\$ AtBat : int 293 315 479 496 321 594 185 298 323 401 \$ Hits : int 66 81 130 141 87 169 37 73 81 92 \$ HmRun : int 1 7 18 20 10 4 1 0 6 17 \$ Runs : int 30 24 66 65 39 74 23 24 26 49 \$ RBI : int 29 38 72 78 42 51 8 24 32 66 \$ Walks : int 14 39 76 37 30 35 21 7 8 65 \$ Years : int 1 14 3 11 2 11 2 3 2 13 \$ CAtBat : int 293 3449 1624 5628 396 4408 214 509 341 5206 \$ CHits : int 66 835 457 1575 101 1133 42 108 86 1332 \$ CHmRun : int 1 69 63 225 12 19 1 0 6 253 \$ CRuns : int 30 321 224 828 48 501 30 41 32 784 \$ CRBI : int 29 414 266 838 46 336 9 37 34 890 \$ CWalks : int 14 375 263 354 33 194 24 12 8 866 \$ League : chr "A" "N" "A" "N" \$ Division : chr "E" "W" "W" "E" \$ PutOuts : int 446 632 880 200 805 282 76 121 143 0 \$ Assists : int 33 43 82 11 40 421 127 283 290 0 \$ Errors : int 20 10 14 3 4 25 7 9 19 0 \$ Salary : num NA 475 480 500 91.5 750 70 100 75 1100 \$ NewLeague: chr "A" "N" "A" "N"	
sur	m(is.na(d\$Salary))	

d = na.omit(d)

2 Comparación de modelos

Se pueden utilizar las siguientes métricas para comparar modelos:

- R-cuadrado
- Residual Sum of Squares, RSS: sum((observed predicted)^2).
- Mean Squared Error, MSE = mean((observed predicted)^2). Cuanto menor sea el MSE, mejor.
- Residual Standard Error, $RSE = sum((observed predicted)^2)/(n-k-1)$.
- Mean Absolute Error, MAE = mean(abs(observed predicted)).

El problema con estas métricas es que dependen del número de regresores considerados. Por tanto se pueden utilizar para **comparar modelos con el mismo número de regresores**. Otras métricas que no tienen este problema son:

• Akaike Information criteria:

$$AIC = \frac{1}{n\hat{\sigma}^2} (RSS + 2k\hat{\sigma}^2)$$

• Estadístico Cp de Mallows:

$$Cp = \frac{1}{n}(RSS + 2k\hat{\sigma}^2)$$

Cp y AIC son proporcionales, $C_p = AIC * \hat{\sigma}^2$.

• Bayesian Information Criteria:

$$BIC = \frac{1}{n}(RSS + \log(n)k\hat{\sigma}^2)$$

• R-cuadrado ajustado:

$$R^{2} - ajustado = 1 - \frac{RSS/(n-k-1)}{TSS/(n-1)}$$

donde:

- k: número de regresores.
- $\hat{\sigma}^2$: estimación del error del modelo, la varianza residual.
- RSS: Residual sum of squares

$$RSS = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2$$

• TSS: Total Sum of Squares

$$TSS = \sum_{i=1}^{n} (y_i - \bar{y}_i)^2$$

Por último, se puede utilizar el método del subconjunto de validación y el de validación cruzada para comparar modelos, sobre todo **desde un punto de vista predictivo**.

3 Métodos de construcción de modelos a partir de un conjunto de variables

3.1 Selección de variables significativas

Algoritmo:

- 1. Mp es el modelo con todos los regresores.
- 2. Para k = p, ..., 1
 - a. Se estima el modelo con k regresores, Mk.
 - b. Se elimina la variable con mayor pvalor de los contrastes individuales.
- 3. Elegir el modelo con el mayor número de regresores significativos.

```
m_1 = lm(Salary \sim ., data = d)
summary(m_1)
##
## Call:
## lm(formula = Salary ~ ., data = d)
##
## Residuals:
##
       Min
                1Q Median
                                3Q
                                       Max
  -907.62 -178.35
                    -31.11
                            139.09 1877.04
##
## Coefficients:
                 Estimate Std. Error t value Pr(>|t|)
##
## (Intercept) 163.10359
                            90.77854
                                       1.797 0.073622 .
## AtBat
                 -1.97987
                             0.63398
                                      -3.123 0.002008 **
## Hits
                  7.50077
                             2.37753
                                       3.155 0.001808 **
## HmRun
                  4.33088
                             6.20145
                                       0.698 0.485616
## Runs
                 -2.37621
                             2.98076
                                      -0.797 0.426122
## RBI
                 -1.04496
                             2.60088
                                      -0.402 0.688204
## Walks
                  6.23129
                             1.82850
                                       3.408 0.000766 ***
## Years
                 -3.48905
                            12.41219
                                      -0.281 0.778874
## CAtBat
                 -0.17134
                             0.13524
                                      -1.267 0.206380
## CHits
                  0.13399
                             0.67455
                                       0.199 0.842713
## CHmRun
                             1.61724
                 -0.17286
                                      -0.107 0.914967
## CRuns
                             0.75046
                  1.45430
                                       1.938 0.053795
## CRBI
                             0.69262
                  0.80771
                                       1.166 0.244691
## CWalks
                             0.32808
                                      -2.474 0.014057 *
                 -0.81157
## LeagueN
                 62.59942
                            79.26140
                                       0.790 0.430424
## DivisionW
               -116.84925
                            40.36695
                                      -2.895 0.004141 **
## PutOuts
                             0.07744
                                       3.640 0.000333 ***
                  0.28189
## Assists
                  0.37107
                             0.22120
                                       1.678 0.094723
## Errors
                 -3.36076
                             4.39163
                                      -0.765 0.444857
## NewLeagueN
                -24.76233
                            79.00263
                                      -0.313 0.754218
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 315.6 on 243 degrees of freedom
## Multiple R-squared: 0.5461, Adjusted R-squared: 0.5106
## F-statistic: 15.39 on 19 and 243 DF, p-value: < 2.2e-16
m_2 = lm(Salary ~ . - CHmRun, data = d)
summary(m 2)
```

```
##
## Call:
## lm(formula = Salary ~ . - CHmRun, data = d)
## Residuals:
##
      Min
                1Q Median
                                3Q
                                       Max
## -914.51 -175.66 -31.72 137.49 1876.79
##
## Coefficients:
##
                 Estimate Std. Error t value Pr(>|t|)
## (Intercept) 163.08380
                           90.59426
                                       1.800 0.073071 .
                -1.97939
                             0.63268
                                     -3.129 0.001970 **
## AtBat
## Hits
                 7.44499
                             2.31485
                                      3.216 0.001475 **
## HmRun
                 4.03304
                             5.52892
                                      0.729 0.466429
## Runs
                -2.27127
                             2.80872 -0.809 0.419504
## RBI
                 -0.96237
                             2.47840
                                      -0.388 0.698131
                            1.80884
                                       3.431 0.000707 ***
## Walks
                 6.20550
## Years
                -3.42721
                           12.37355
                                     -0.277 0.782031
## CAtBat
                            0.13146 -1.328 0.185336
                -0.17461
## CHits
                 0.18359
                             0.48861
                                      0.376 0.707440
## CRuns
                 1.40160
                             0.56455
                                      2.483 0.013714 *
## CRBI
                 0.73870
                             0.25026
                                      2.952 0.003468 **
## CWalks
                            0.31424 -2.551 0.011343 *
                -0.80172
                63.12305
                           78.94944
                                      0.800 0.424756
## LeagueN
## DivisionW
              -116.85917
                            40.28499 -2.901 0.004062 **
## PutOuts
                 0.28224
                             0.07721
                                       3.655 0.000315 ***
## Assists
                 0.37319
                             0.21986
                                       1.697 0.090902 .
                             4.37472
                                     -0.775 0.439262
## Errors
                -3.38913
               -25.31356
                           78.67426 -0.322 0.747916
## NewLeagueN
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 314.9 on 244 degrees of freedom
## Multiple R-squared: 0.5461, Adjusted R-squared: 0.5126
## F-statistic: 16.31 on 18 and 244 DF, p-value: < 2.2e-16
m_3 = lm(Salary ~ . - CHmRun - Years, data = d)
summary(m_3)
##
## Call:
## lm(formula = Salary ~ . - CHmRun - Years, data = d)
##
## Residuals:
##
      Min
                1Q Median
                                3Q
                                       Max
## -912.02 -180.92 -34.89 138.05 1881.51
## Coefficients:
##
                 Estimate Std. Error t value Pr(>|t|)
                           73.41097
                                       2.022 0.044268 *
## (Intercept) 148.43333
## AtBat
                -1.95091
                             0.62309 -3.131 0.001953 **
## Hits
                             2.30241
                 7.39141
                                       3.210 0.001503 **
                 4.08280
                             5.51558
## HmRun
                                      0.740 0.459869
## Runs
                -2.23967
                             2.80111 -0.800 0.424737
## RBI
                -0.99402
                             2.47109 -0.402 0.687845
```

```
## Walks
                  6.19706
                              1.80517
                                        3.433 0.000701 ***
## CAtBat
                 -0.19133
                              0.11657
                                       -1.641 0.102010
                              0.48050
## CHits
                  0.20673
                                        0.430 0.667398
## CRuns
                  1.42497
                              0.55716
                                        2.558 0.011144 *
## CRBI
                  0.74147
                              0.24958
                                        2.971 0.003265 **
                 -0.80376
                              0.31356
## CWalks
                                       -2.563 0.010966 *
                 64.19282
                             78.70619
                                        0.816 0.415521
## LeagueN
## DivisionW
               -116.06176
                             40.10620
                                       -2.894 0.004148 **
## PutOuts
                  0.28303
                              0.07702
                                        3.675 0.000292 ***
## Assists
                  0.37732
                              0.21894
                                        1.723 0.086083
## Errors
                 -3.31999
                              4.35935
                                       -0.762 0.447044
                -24.88922
                             78.51099
                                       -0.317 0.751502
## NewLeagueN
##
                   0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
## Signif. codes:
##
## Residual standard error: 314.3 on 245 degrees of freedom
## Multiple R-squared: 0.546, Adjusted R-squared: 0.5144
## F-statistic: 17.33 on 17 and 245 DF, p-value: < 2.2e-16
```

Y así sucesivamente. Este método de suele utilizar cuando utilizamos el modelo para explicar relaciones entre variables, por lo que estamos interesados en variables significativas. Cuando el objetivo es predecir se utilizan los métodos que se indican a continuación.

3.2 Best subset selection

Algoritmo:

```
Para k = 1, 2, ..., p:
```

- Estimar todos los modelos de k regresores (hay $\binom{p}{k}$ modelos posibles).
- Elegir el que tenga menor RSS o mayor \mathbb{R}^2 . Este será el modelo \mathbb{M}_k .

```
library(leaps)
m2 = regsubsets(Salary ~ ., data = d)
summary(m2)
## Subset selection object
## Call: regsubsets.formula(Salary ~ ., data = d)
  19 Variables (and intercept)
##
              Forced in Forced out
## AtBat
                  FALSE
                              FALSE
## Hits
                  FALSE
                              FALSE
## HmRun
                  FALSE
                              FALSE
## Runs
                  FALSE
                              FALSE
## RBI
                  FALSE
                              FALSE
## Walks
                  FALSE
                              FALSE
## Years
                  FALSE
                              FALSE
## CAtBat
                  FALSE
                              FALSE
## CHits
                  FALSE
                              FALSE
## CHmRun
                  FALSE
                              FALSE
## CRuns
                              FALSE
                  FALSE
## CRBI
                  FALSE
                              FALSE
## CWalks
                  FALSE
                              FALSE
## LeagueN
                  FALSE
                              FALSE
## DivisionW
                  FALSE
                              FALSE
## PutOuts
                  FALSE
                              FALSE
```

```
## Assists
                    FALSE
                                 FALSE
## Errors
                    FALSE
                                 FALSE
## NewLeagueN
                    FALSE
                                 FALSE
## 1 subsets of each size up to 8
##
   Selection Algorithm: exhaustive
##
             AtBat Hits HmRun Runs RBI Walks Years CAtBat CHits CHmRun CRuns CRBI CWalks LeagueN Division
      (1)
                                                         11 11
                                                                 11 11
                                                                        11 11
                                                                                11 11
                                                                                       "*"
                                                                                            11 11
                    "*"
                                                                                       "*"
## 2
      (1)
                                                                                                              11 11
## 3
       (1)
             11 11
                    11 * 11
                                                                                       "*"
## 4
      (1)
             11 11
                                                                                       "*"
                                                                                .. ..
                                                                                       "*"
      (1)"*"
      (1)
             "*"
                     "*"
                                                                                       "*"
                                                                                                              "*"
## 6
                                                  11 11
       (1)
             11 11
                                                         "*"
                                                                                .. ..
                                                                                                              "*"
## 7
## 8 (1) "*"
                                                                        "*"
                                                                                11 * 11
                                                                                                              "*"
```

El resultado son los mejores 8 modelos (por defecto):

- la primera línea es el mejor modelo (en términos de R²) de una variable. La variable seleccionada es la que aparece con un asterisco, CRBI.
- la segunda linea es el mejor modelo (en términos de R²) de dos variables, **Hits** y **CRBI**.
- y así sucesivamente.

2

3

(1)

(1)

"*"

11 🕌 11

11 11

11 11

11 11

.

..

Podemos seleccionar el numero de modelos que nos devuelve con numax:

```
m_best = regsubsets(Salary ~ ., data = d, nvmax = 19)
summary(m_best)
## Subset selection object
## Call: regsubsets.formula(Salary ~ ., data = d, nvmax = 19)
## 19 Variables (and intercept)
##
              Forced in Forced out
                   FALSE
## AtBat
                              FALSE
## Hits
                   FALSE
                              FALSE
## HmRun
                   FALSE
                              FALSE
## Runs
                   FALSE
                              FALSE
## RBI
                   FALSE
                              FALSE
## Walks
                   FALSE
                              FALSE
## Years
                   FALSE
                              FALSE
## CAtBat
                   FALSE
                              FALSE
                   FALSE
## CHits
                              FALSE
## CHmRun
                   FALSE
                              FALSE
## CRuns
                   FALSE
                              FALSE
## CRBI
                   FALSE
                              FALSE
## CWalks
                   FALSE
                              FALSE
## LeagueN
                   FALSE
                              FALSE
## DivisionW
                   FALSE
                              FALSE
## PutOuts
                   FALSE
                              FALSE
## Assists
                   FALSE
                              FALSE
## Errors
                   FALSE
                              FALSE
## NewLeagueN
                   FALSE
                              FALSE
## 1 subsets of each size up to 19
## Selection Algorithm: exhaustive
             AtBat Hits HmRun Runs RBI Walks Years CAtBat CHits CHmRun CRuns CRBI CWalks LeagueN Divisi
##
                                                                           11 11
                                     11 11 11 11
                                                                    11 11
##
      (1
          )
                               11 11
                                                                                 "*"
```

11 11

11 11

11 11

11 11

11 11

"*"

اليواا

11 11

11 11

11 11

11 11


```
11 11
                                                                                     11 11
                                                                                                             11 11
## 4
        (1)
                                                                                              11 11
                                                                                                                         11
## 5
          1
             )
##
        (1
                 "*"
##
   7
          1
                                                                             "*"
            )
                                                                                     "*"
##
   8
          1
                 "*"
## 9
        ( 1
                 "*"
                                                                                              "*"
            )
## 10
         (1
                                                                                               "*"
                                                                                                      "*"
                                                                                                             "*"
                                                                                                                      "*"
           1
              )
                 "*"
                                                                    "*"
## 11
         (
##
   12
           1
              )
##
   13
         ( 1
              )
                 "*"
                                                                                              "*"
                                                                                                             "*"
##
   14
         (1
                 "*"
                                                                                     11 11
                                                                                                             "*"
              )
                 "*"
                                                                    "*"
                                                                             "*"
                                                                                               "*"
                                                                                                      "*"
                                                                                                             "*"
                                                                                                                      "*"
##
   15
           1
                                                                                     11 11
##
   16
           1
                 "*"
                                                                   "*"
                                                                                              "*"
                                                                                                                      "*"
##
   17
## 18
         (1
              )
         (1)
                                        "*"
                                                                                                                      الياا
## 19
                 "*"
                                11 🕌 11
                                                            الياا
                                                                    11 🕌 11
```

"*"

Podemos trabajar con R2 o con las otras métricas:

```
m_best_summary = summary(m_best)
names(m_best_summary)
```

```
## [1] "which" "rsq" "rss" "adjr2" "cp" "bic" "outmat" "obj"
plot(m_best_summary$adjr2, xlab = "Numero de variables", ylab = "R2 ajustado", type = "b")
```




Buscamos el máximo:

```
which.max(m_best_summary$adjr2)
```

```
## [1] 11
```

Si utilizamos el criterio del Cp (que es equivalente al AIC):

```
plot(m_best_summary$cp, xlab = "Numero de variables", ylab = "Cp", type = "b")
```



which.min(m_best_summary\$cp)

[1] 10

Justificación: el RSS disminuye con el número de regresores k. Por eso penalizamos incluyendo un término que contiene a k.

Los coeficinetes estimados con ese modelo son:

```
coef(m_best,10)
                                                                                                 CRBI
##
    (Intercept)
                         AtBat
                                        Hits
                                                     Walks
                                                                   CAtBat
                                                                                  CRuns
                                                                                                             CWa
##
    162.5354420
                   -2.1686501
                                   6.9180175
                                                 5.7732246
                                                              -0.1300798
                                                                              1.4082490
                                                                                            0.7743122
                                                                                                         -0.8308
##
        Assists
      0.2831680
##
```

3.3 Método Forward-Stepwise

Algoritmo:

- 1. M0 es el modelo sin regresores.
- 2. Para k = 0, ..., (p-1)
 - a. A partir del modelo con k regresores, M_k , estimar todos los modelos posibles con (k+1) regresores.
 - b. Elegir el que tenga menor RSS o mayor \mathbb{R}^2 . Este será el modelo \mathbb{M}_{k+1} .
- 3. Elegir el mejor modelo de M0, . . . , \mathbf{M}_p utilizando validación cruzada, Cp, AIC, BIC, R2-ajustado.

```
m_fwd = regsubsets(Salary ~ ., data = d, nvmax = 19, method = "forward")
summary(m_fwd)
```

```
## Subset selection object
## Call: regsubsets.formula(Salary ~ ., data = d, nvmax = 19, method = "forward")
## 19 Variables (and intercept)
## Forced in Forced out
## AtBat FALSE FALSE
## Hits FALSE FALSE
## HmRun FALSE FALSE
```

```
## Runs
                     FALSE
                                   FALSE
## RBI
                     FALSE
                                   FALSE
                                   FALSE
## Walks
                     FALSE
                     FALSE
                                   FALSE
## Years
##
   CAtBat
                     FALSE
                                   FALSE
##
   CHits
                     FALSE
                                   FALSE
   CHmRun
                     FALSE
                                   FALSE
## CRuns
                     FALSE
                                   FALSE
## CRBI
                     FALSE
                                   FALSE
## CWalks
                     FALSE
                                   FALSE
## LeagueN
                     FALSE
                                   FALSE
## DivisionW
                     FALSE
                                   FALSE
## PutOuts
                     FALSE
                                   FALSE
## Assists
                     FALSE
                                   FALSE
## Errors
                     FALSE
                                   FALSE
## NewLeagueN
                     FALSE
                                   FALSE
   1 subsets of each size up to 19
   Selection Algorithm: forward
##
               AtBat Hits HmRun Runs RBI Walks Years CAtBat CHits CHmRun CRuns CRBI CWalks LeagueN Divisi
                                                                                                            11 11
                                                                              11 11
                                                                                      11 11
                                                                                                    11 11
                                                                                              "*"
##
       (1
                                                                                              "*"
                               11
                                                                         11
                                                                                      11 11
                                                                                                            "
                                                                                                              11
##
   2
       (1)
                                                                                      11 11
##
   3
       (1)
                  11
                             11
                               11
                                                                                              11 * 11
                                                                                                    11
       (1
                                                                                              "*"
## 4
           )
                             11
                                                                                      11 11
                                                                                                            11
## 5
       (
         1
                                                                                              "*"
       ( 1
                "*"
                                                                                              "*"
## 6
           )
##
   7
       (1)
                                                                                      11 11
                                                                                              "*"
                                                                                                            11
                                                                                                            11
## 8
       (1
           )
                "*"
                                                                                      "*"
                                                                                              "*"
                                                                                                    "*"
##
   9
       (1
                             11 11
                                    11 11
                                                                      11 11
                                                                              11
                                                                                              11 * 11
                                                                                                    "*"
                                                                                                            11 11
                                                                                      "*"
                                                                                              "*"
                                                                                                    "*"
## 10
        (1
             )
                                    11 11
                                                                                                    "*"
## 11
        (
          1
                                     "*"
                                                                                       "*"
                                                                                              "*"
                                                                                                    "*"
                                                                                                            "*"
                "*"
                       "*"
                                                              " * "
## 12
        (
          1
             )
##
   13
        (
          1
             )
                "*"
                                    "*"
                                                                      11 11
                                                                              11
                                                                                              "*"
        (1
               "*"
                                    11 🕌 11
                                                                                      11 🕌 11
                                                                                              "*"
                                                                                                    "*"
                                                                                                            11 🕌 11
##
   14
             )
               "*"
                                             11
                                                                              11 11
                                                                                              "*"
##
   15
        (1
             )
                                                                              11 11
                                                                                      "*"
                                                                                              "*"
                                                                                                    "*"
                             " * "
                                    "*"
                                                              11 🕌 11
                                                                      11 🕌 11
                                                                                                            11 🕌 11
##
   16
          1
             )
                                    "*"
                                                       11 11
                                                                              11
                                                                                11
                                                                                      "*"
                                                                                              "*"
##
   17
        (1
             )
                                                                                                    "*"
## 18
        (1
             )
                             11 * 11
                                    11 * 11
                                                              "*"
                                                                                              "*"
                                                                                                            "*"
## 19
        (1)
m_fwd_summary = summary(m_fwd)
which.min(m_fwd_summary$cp)
## [1] 10
coef(m_fwd, 10)
##
     (Intercept)
                            AtBat
                                             Hits
                                                           Walks
                                                                          CAtBat
                                                                                           CRuns
                                                                                                            CRBI
                                                                                                                          CWa
                                                                                                                     -0.8308
##
    162.5354420
                      -2.1686501
                                      6.9180175
                                                      5.7732246
                                                                     -0.1300798
                                                                                      1.4082490
                                                                                                      0.7743122
##
         Assists
##
       0.2831680
```

3.4 Método Backward-Stepwise

Algoritmo:

1. Mp es el modelo con todos los regresores.

- 2. Para k = p, ..., 1
 - a. A partir del modelo con k regresores, M_k , estimar todos los modelos posibles con (k-1) regresores.
 - b. Elegir el que tenga menor RSS o mayor \mathbb{R}^2 . Este será el modelo \mathbb{M}_{k-1} .
- 3. Elegir el mejor modelo de M0, . . . , \mathbf{M}_p utilizando validación cruzada, Cp, AIC, BIC, R2 ajustado.

```
m_bwd = regsubsets(Salary ~ ., data = d, nvmax = 19, method = "backward")
summary(m_bwd)
## Subset selection object
   Call: regsubsets.formula(Salary ~ ., data = d, nvmax = 19, method = "backward")
   19 Variables
                    (and intercept)
##
                 Forced in Forced out
## AtBat
                      FALSE
                                    FALSE
## Hits
                      FALSE
                                    FALSE
## HmRun
                      FALSE
                                    FALSE
## Runs
                      FALSE
                                    FALSE
## RBI
                      FALSE
                                    FALSE
## Walks
                      FALSE
                                    FALSE
                      FALSE
## Years
                                    FALSE
## CAtBat
                      FALSE
                                    FALSE
## CHits
                      FALSE
                                    FALSE
## CHmRun
                      FALSE
                                    FALSE
## CRuns
                      FALSE
                                    FALSE
## CRBI
                      FALSE
                                    FALSE
## CWalks
                      FALSE
                                    FALSE
## LeagueN
                      FALSE
                                    FALSE
## DivisionW
                      FALSE
                                    FALSE
## PutOuts
                      FALSE
                                    FALSE
## Assists
                      FALSE
                                    FALSE
## Errors
                      FALSE
                                    FALSE
## NewLeagueN
                      FALSE
                                    FALSE
   1 subsets of each size up to 19
   Selection Algorithm: backward
                AtBat Hits
                             HmRun Runs RBI Walks Years CAtBat
                                                                        CHits
                                                                                CHmRun CRuns CRBI CWalks LeagueN Divisi
                                     11 11
                                              11
                                                11
                                                         11 11
                                                                  11
                                                                           11
                                                                                         "*"
                                                                                                   11
##
       (1)
   1
                                                                                                                  11
   2
       ( 1
                              11
                                11
                                                           11
                                                                                11
                                                                                         "*"
                                                                                                 11 11
                                                                                                       11
##
                        "*"
                                                                                         "*"
   3
       (1
##
            )
                              . .
                                      .. ..
                                                                                 "
                                                                                         "*"
         1
                                                                                                 11 11
##
   4
       (
            )
                                                                                         "*"
                                                                                                 11
## 5
       (1
                "*"
                        "*"
            )
       (1
                "*"
                                                                         11
                                                                                11
                                                                                         "*"
                                                                                                 11 11
                                                                                                       11 11
                                                                                                                11
   6
            )
                                                                                         "*"
                                                                                                       "*"
                "*"
                        "*"
##
   7
       (1
            )
       (1
                "*"
                              11 11
                                      11 11
                                                         11 11
                                                                         11 11
                                                                                11
                                                                                         "*"
                                                                                                 "*"
                                                                                                       "*"
                                                                                                                11 11
##
   8
            )
                                                                                                                "
                "*"
                        "*"
                                                                                         11 * 11
                                                                                                 11 * 11
                                                                                                       11 * 11
                                                                                                                          "*"
## 9
       ( 1
            )
                              11 11
                                      .. ..
                                                                         11 11
                                                                                •
                                                                                         "*"
                                                                                                 "*"
                                                                                                       "*"
                                                                                                                11 11
## 10
         (1)
           1
             )
                "*"
                              11 11
                                                                11 * 11
                                                                                         "*"
                                                                                                 "*"
                                                                                                       11 * 11
                                                                                                                11 * 11
                                                                                                                          11 * 11
## 11
         (
                              11 11
                                      "*"
                                              11
                                                                         11 11
                                                                                11
                                                                                         "*"
                                                                                                 "*"
##
         (
           1
             )
                "*"
   12
                                     "*"
                        "*"
                                                                         11 11
                                                                                11 11
##
   13
         (1
             )
                "*"
                              11 11
                                                                11 * 11
                                                                                         11 * 11
                                                                                                 11 * 11
                                                                                                       11 * 11
                                                                                                                11 * 11
                                                                                                                          11 * 11
                "*"
                        "*"
   14
         (1
             )
                                     "*"
                                              11
                                                         11 11
                                                                         11 11
                                                                                11 11
                                                                                                 "*"
                                                                                                       "*"
                                                                                                                "*"
##
                                                                                 11 11
                              "*"
                                      الياا
                                                                         11 🕌 11
                                                                                         "*"
                                                                                                 "*"
                                                                                                       11 🕌 11
                                                                                                                11 🕌 11
                "*"
                                                                11 🕌 11
##
   15
         (
           1
             )
                                      "*"
                                                                                11 11
                                                                                                 "*"
                                                                                                       "*"
##
   16
         (1
             )
                "*"
   17
                        "*"
                              "*"
                                      "*"
                                                        11 11
                                                                         "*"
                                                                                11 11
                                                                                         "*"
                                                                                                 "*"
                                                                                                       "*"
                                                                                                                "*"
         (1
             )
                                                                "*"
                                      "*"
                                                                                                 "*"
                                                                                                       "*"
             )
                        "*"
                              "*"
                                                         "*"
                                                                "*"
                                                                         "*"
                                                                                          "*"
                                                                                                                "*"
                                                                                                                          "*"
         ( 1
## 18
                                            "*" "*"
                                                                                         "*"
## 19
         (1)
                "*"
                              "*"
                                      "*"
                                                        11 * 11
                                                                "*"
                                                                         11 🕌 11
                                                                                "*"
                                                                                                 "*"
                                                                                                       "*"
                                                                                                                "*"
                                                                                                                          "*"
```

```
m_bwd_summary = summary(m_bwd)
which.min(m_bwd_summary$cp)
## [1] 10
coef(m_bwd, 10)
##
    (Intercept)
                         AtBat
                                        Hits
                                                     Walks
                                                                  CAtBat
                                                                                 CRuns
                                                                                                CRBI
                                                                                                            CWa.
                   -2.1686501
                                  6.9180175
                                                5.7732246
                                                             -0.1300798
                                                                             1.4082490
                                                                                                        -0.8308
##
    162.5354420
                                                                                           0.7743122
##
        Assists
##
      0.2831680
```

Es el mismo que antes.

3.5 Eligiendo el mejor modelo utilizando subconjuntos de validación

```
set.seed(1)
n = nrow(d)
n_train = round(0.6*n)
n_test = n - n_train

pos = 1:n
pos_train = sample(pos,n_train,replace = F) # muestreo sin reemplazamiento
pos_test = pos[-pos_train]

# dividimos los datos en training set y validation set
datos_train = d[pos_train,]
datos_test = d[pos_test,]
```

Estimamos todos los modelos posibles con los datos de entrenamiento


```
m_val = regsubsets(Salary ~ ., data = datos_train, nvmax = 19)
```

Vamos calcular el error de prediccion (MSE) de este modelo en los datos test. Como no existe la funcion predecir a partir de modelos estimados con regsubsets(), se ha programado en (descargar):

```
source("funciones/regsubsets_predict.R")
predict.regsubsets
```

```
## function(objeto_regsubsets, newdata, id){
##
     # funcion para predecir con regsubsets
##
     # objeto_regsubsets: objeto calculado con la funcion regbsubsets()
##
     # newdata: datos para predecir (data.frame)
     # id: numero de variables incluidas en el modelo objeto_regsubsets
##
##
##
     formu = as.formula(objeto_regsubsets$call[[2]])
##
##
     X_mat = model.matrix(formu,newdata)
     coefi = coef(objeto_regsubsets, id)
##
##
     X col = names(coefi)
##
     pred = X_mat[,X_col] %*% coefi
##
     return(pred)
## }
source("funciones/MSE.R")
mse_val = rep(0,19)
```

```
for (i in 1:19){
   pred_i = predict(m_val,datos_test,i)
   mse_val[i] = MSE(datos_test$Salary,pred_i)
}
plot(mse_val, type = "b")
```



```
which.min(mse_val)
```

[1] 6

Para calcular los coeficientes del modelo de regresión finales, es preferible hacerlo con todos los datos:

```
m_val_final = regsubsets(Salary ~ ., data = d, nvmax = 19)
coef(m_val_final,6)
```

```
## (Intercept) AtBat Hits Walks CRBI DivisionW PutOuts ## 91.5117981 -1.8685892 7.6043976 3.6976468 0.6430169 -122.9515338 0.2643076
```

3.6 Eligiendo el mejor modelo utilizando Cross-Validation

Función para obtener las posiciones de train y de test:

```
source("funciones/cross_val_pos.R")
```

Datos de los folds:

```
num_folds = 10
set.seed(1)
pos = cross_val_pos(nrow(d),num_folds)
```

Calculamos el error cometido en cada fold por cada modelo:


```
mse_cv = matrix(0, nrow = num_folds, ncol = 19)
for (i in 1:num_folds){
    # datos de training y de validation de cada fold
    datos_train = d[pos$train[[i]],]
```

```
datos_test = d[pos$test[[i]],]

m_cv = regsubsets(Salary ~ .,data = datos_train, nvmax = 19)

for (j in 1:19){
    pred = predict(m_cv,newdata = datos_test, id = j)
        mse_cv[i,j] = MSE(datos_test$Salary,pred)
    }
}
```

```
mse_cv_med = apply(mse_cv, 2, mean)
plot(mse_cv_med, type = "b")
```



El que tiene menor error es el de 9 variables. Lo aplicamos a todos los datos:

6.65672102

-1.93676754

146.24960033

```
m_cv_final = regsubsets(Salary ~ ., data = d, nvmax = 19)
coef(m_cv_final,9)

## (Intercept) AtBat Hits Walks CAtBat CRuns CRBI
```

5.55204413

-0.09953904

1.25067124

0.66176849